IDEALENS / PROJECT LEARNING

RAG를 코드로 이해하는 안내서

아이디어 입력부터 검색, 근거 검증, 보고서와 평가까지 IdeaLens의 실제 흐름을 따라가는 시각 학습 자료



누구를 위한 자료인가

IdeaLens 코드를 처음 읽는 개발자와 RAG 구현의 품질 기준을 익히려는 팀원

학습 후 할 수 있는 일

검색 후보가 만들어지는 경로를 추적하고, 근거와 미확인을 구분해 평가 계획을 세운다

읽는 기준

설계 문서보다 현재 코드·스키마·테스트를 기준으로 동작을 확인한다

핵심 관점

좋은 RAG는 그럴듯한 답을 만드는 데서 끝나지 않습니다. 어떤 자료를 어디서 찾았고, 무엇을 확인했으며, 무엇은 아직 모르는지 다시 추적할 수 있어야 합니다.

01 / SYSTEM MAP

RAG 전체 흐름

IdeaLens에서는 색인 준비와 사용자 분석 실행이 서로 다른 작업입니다. 아래 흐름에서 각 단계의 입력·출력 계약을 따라가면, 자료가 보고서 근거가 되는 경로를 볼 수 있습니다.



코드 따라가기

단계	먼저 볼 파일	확인 질문
계약	src/idea_schemas.py · src/patent_schemas.py · src/market_schemas.py	ID·상태·인용 필드는 어디서 정의되는가?
수집·청킹	src/ingestion/patent_processor.py · market_processor.py · dart_processor.py	원문 범위와 출처가 어떻게 보존되는가?
검색	src/retrieval/engine.py · patent_search.py · market_search.py	후보 점수와 정렬은 어떻게 만들어지는가?
분석·통합	src/services/ · src/pipeline.py · src/pipeline_execution.py	부분 실패가 어떻게 결과에 남는가?

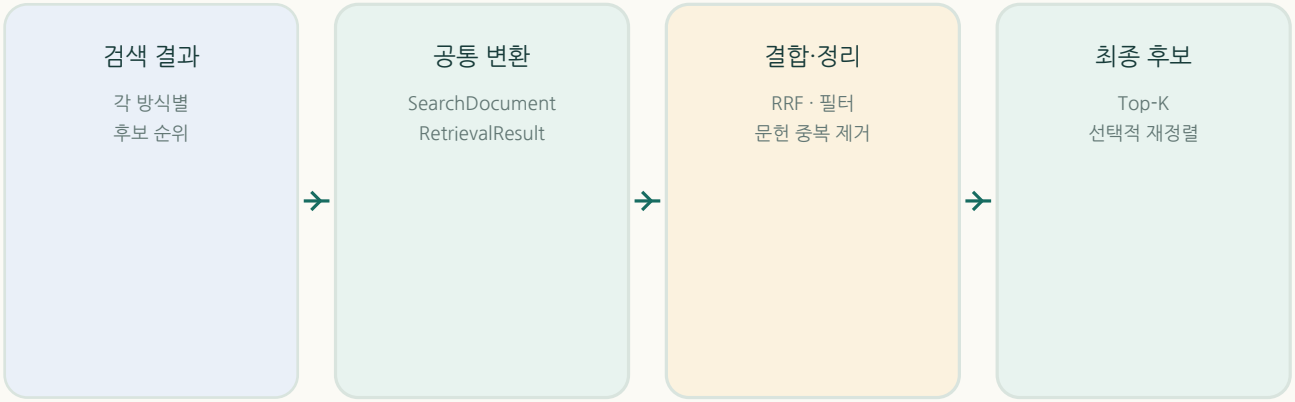
02 / RETRIEVAL

검색은 후보를 만드는 단계

Dense와 BM25는 서로 다른 단서를 사용합니다. Hybrid는 두 순위를 결합하고, 선택적 reranker는 만들어진 후보를 다시 정렬합니다. 이 단계가 답변의 진실성을 보장하지는 않습니다.

방식	무엇을 비교하나	강점	주의할 점
Dense	질의·문서 임베딩의 벡터 거리	표현이 달라도 의미가 가까운 자료를 찾을 수 있음	질의 임베딩과 모델·컬렉션 호환성 확인
BM25	질의 토큰과 문서 내 단어 빈도·희소성	고유 기술어·명시적 용어가 맞을 때 유용	특허 BM25/Hybrid는 현재 분야 코퍼스 전체를 메모리로 읽음
Hybrid	Dense 순위 + BM25 순위의 RRF	서로 다른 검색 신호를 보완할 가능성	RRF 점수와 원점수는 같은 척도가 아님
Reranker	질의-후보 쌍의 별도 모델 점수	상위 후보 순서를 더 정교하게 조정할 수 있음	모델 로드·추가 지연·의존성 비용 고려

후보의 생애



현재 확인된 구조

특허 Dense는 벡터 후보를 가져옵니다. BM25/Hybrid는 분야 필터에 맞는 문서·메타데이터 전체를 읽어 메모리에서 BM25를 계산합니다.

개선 검증 원칙

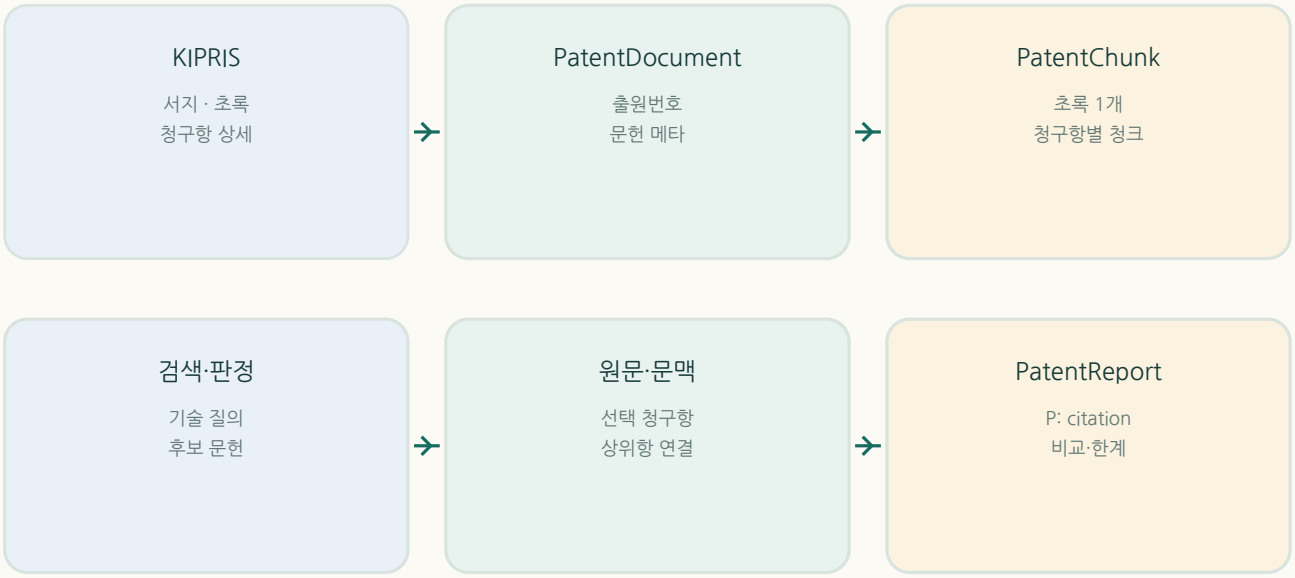
전체 코퍼스 로딩이 실제 병목인지 같은 조건에서 계측합니다. 후보 제한을 바꾸면 고정 질의·사람 라벨로 검색 품질도 비교합니다.

읽을 파일: src/retrieval/engine.py · src/retrieval/patent_search.py · src/retrieval/market_search.py

03 / PATENT PATH

특허 RAG: 청구항 단위로 추적

특허 흐름의 중심은 문헌과 청구항의 관계를 잃지 않는 것입니다. 검색 결과가 최종 분석에 쓰이기 전에 관련성 판단, 원문 보강, 문맥 선택, 인용 검증을 거칩니다.



특허 경로의 주요 파일

역할	코드 위치	왜 읽나
청구항 정리·청킹	src/ingestion/patent_processor.py	항 번호, 독립·종속 유형, 참조 항과 버전을 확인
색인 저장	src/retrieval/patent_store.py	청크 ID, 증분 갱신, 배치 임베딩을 확인
검색·질의 계획	src/retrieval/patent_search.py	기술 요소 질의와 검색 모드별 후보 흐름을 확인
서비스·문맥	src/services/patent_service.py · patent_context.py	문헌 후보, 청구항 보강과 분석 문맥 선택을 확인

주의: 인용문이 원문에 포함된다는 검사는 인용이 주장을 충분히 뒷받침한다는 뜻이 아닙니다. 특허 비교는 예비 조사이며 법률 판단을 대체하지 않습니다.

04 / MARKET PATH

시장 RAG: 신호의 성격을 구분

시장 자료는 출처마다 보여 주는 것이 다릅니다. 검색 결과를 하나의 '수요 점수'로 합치지 않고, 근거 유형과 분석 차원에 맞게 다룹니다.

자료	색인에 들어가는 내용	말할 수 있는 범위	넘지 말아야 할 결론
뉴스	제목·요약·URL·발행일	보도된 사례·사업 신호	요약을 기사 전문 인용처럼 표현하지 않기
DART	사업 내용 섹션의 정제 텍스트 청크	기업이 공시한 사업 설명	기업 공시를 전체 시장 규모로 일반화하지 않기
조달	공공 입찰 공고·구매 조건	공공 구매 사례 신호	모든 고객군의 수요 증거로 확대하지 않기
검색 관심도	기간별 상대 검색 지표	검색 관심 변화	구매 의사·매출·시장 규모로 해석하지 않기

시장 분석 경로



Fact

근거가 인용된 확인 사실. source와 citation 연결을 따라가야 합니다.

Signal

관련 자료에서 확인한 사업 신호. 곧바로 직접 수요를 뜻하지 않습니다.

Unknown

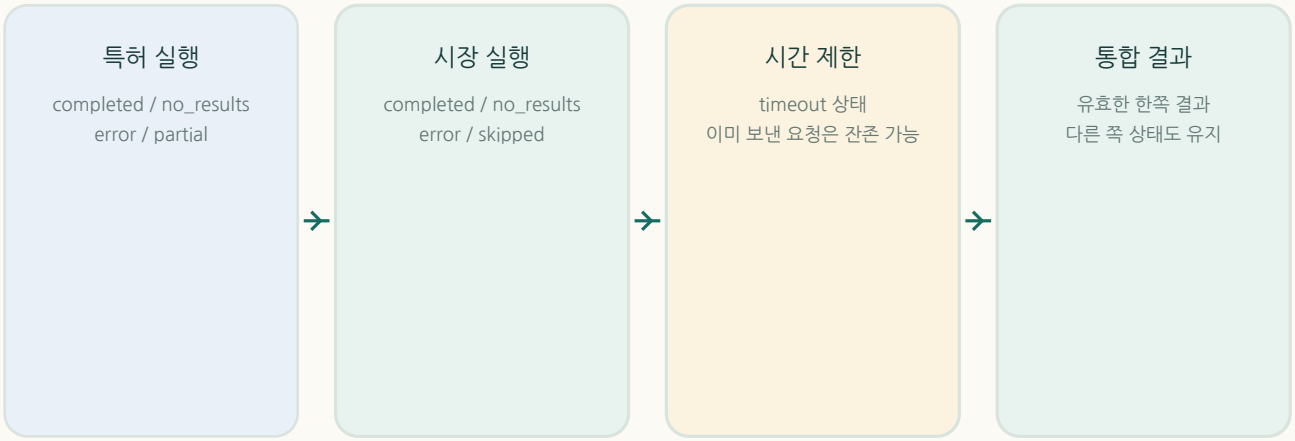
자료가 부족하거나 판정할 수 없는 내용. 추정값으로 채우지 않습니다.

읽을 파일: src/services/market_service.py · src/retrieval/market_relevance.py · src/generation/market_analysis.py · src/generation/market_claims.py

05 / TRUSTWORTHY OUTPUT

근거·불확실성·부분 실패

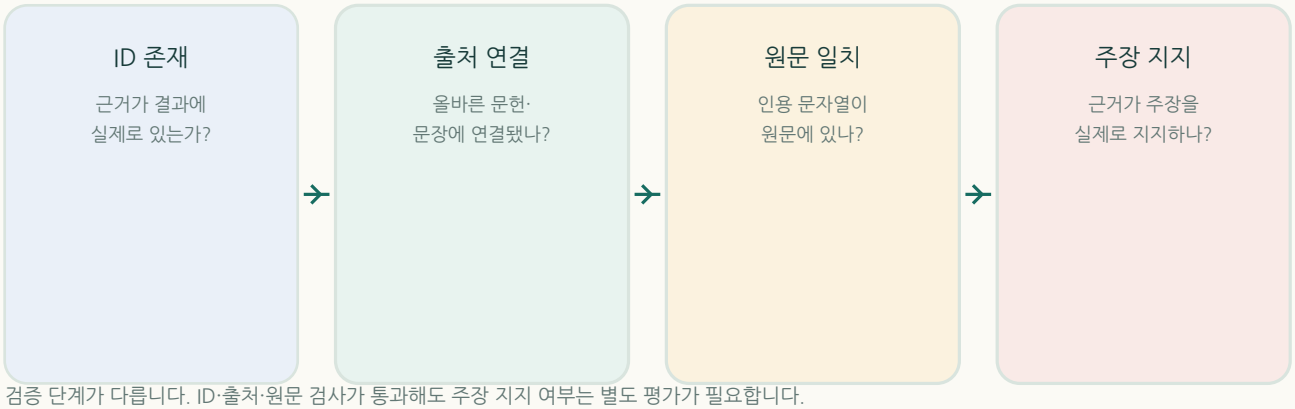
사용자가 믿고 검토할 수 있는 결과는 확정과 미확인을 섞지 않습니다. 상태는 자료가 어디까지 처리됐는지 알려 주고, 근거는 주장을 다시 확인할 경로를 제공합니다.



보고서에서 구분할 네 가지

구분	출처	표현 예	검토 포인트
확인 사실	검색된 원자료	인용 근거가 보여 주는 내용	citation ID와 원문 위치가 연결되는가?
사용자 주장	입력·답변	사용자가 제공한 가정	조사로 검증된 사실처럼 바뀌지 않았는가?
AI 가설	모델의 추론	추가 검증이 필요한 해석	근거 사실과 구별되어 표시되는가?
미확인	자료 부족·실패	확인할 자료가 부족함	빈칸을 수치나 확신으로 채우지 않았는가?

검증 사다리



검증 단계가 다릅니다. ID·출처·원문 검사가 통과해도 주장 지지 여부는 별도 평가가 필요합니다.

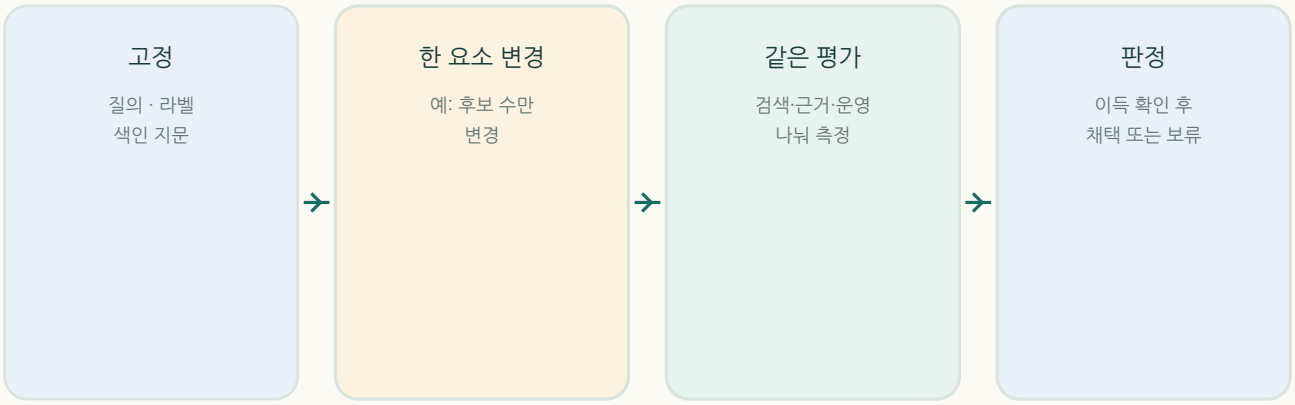
06 / EVALUATION

평가 없이는 개선을 말하지 않는다

RAG 품질은 검색 적중률 하나로 설명되지 않습니다. 동일한 조건에서 검색, 근거, 답변, 운영 지표를 나눠 비교해야 합니다.

평가 층위	대표 질문	예시 지표·검토
검색	관련 문헌을 찾았나?	Recall@k · Precision@k · MRR · nDCG
근거	인용이 맞고 주장을 뒷받침하나?	citation 존재 · 문서 소속 · 원문 일치 · 사람의 지지 판정
답변	사실을 왜곡하거나 과장했나?	사실 오류 · 누락 · 과도한 결론 · 미확인 처리
운영	실행 비용과 안정성은 어떤가?	지연 · 호출 수 · 토큰/비용 · 실패율

재현 가능한 비교 실험



현재 특허 평가

고정 질의·후보 자료가 있어도 사람 정답 라벨을 확인하기 전에는 검색 품질 수치를 결론으로 쓰지 않습니다.

시장 결과 파일

저장된 평가 CSV는 과거 실행 결과입니다. 현재 데이터·색인·조건과 동일한 기준이라고 가정하지 않습니다.

도구 위치: evaluation/patent_cases.json · evaluation/market_cases.json · evaluation/patent_groundedness.py · evaluation/market_answer_eval.py

07 / STUDY PLAN

직접 따라 읽는 학습 로드맵

회차	실습	완료 기준
1. 계약과 문서	PatentDocument → PatentChunk 필드 추적	문헌 ID·청크 ID·출처 메타데이터를 설명한다
2. 검색	dense/BM25/Hybrid 테스트와 정렬 코드 읽기	같은 후보가 모드별로 왜 다른 순위인지 설명한다
3. 근거	검색 결과에서 citation 검증까지 호출 추적	원문 일치 검사와 주장 지지 판정을 구분한다
4. 상태	한 영역 실패·시간 초과 테스트 읽기	유효 결과 보존과 in-flight 요청 제한을 설명한다
5. 평가	라벨·결과 파일·실행 지문 점검	비교 가능한 결과와 비교 불가 결과를 구별한다

코드 탐색 질문

• 어떤 변경이 재임베딩을 일으키나? • 메타데이터 필터는 Dense와 BM25에 똑같이 적용되나? • 중복 제거는 후보 제한 전인가 후인가? • Ollama 선택은 채팅·임베딩·외부 자료 수집 각각에 어떤 영향을 주나? • 결과를 다시 열 때 추가 분석 호출이 생기나?

용어 빠르게 보기

용어	뜻
Chunk	검색 단위로 나눈 문서 텍스트
Embedding	텍스트를 벡터로 바꾸어 의미 유사도를 계산하는 표현
RRF	여러 검색 순위를 역순위 점수로 결합하는 방식
Reranker	후보를 별도 모델 점수로 다시 정렬하는 단계
Citation ID	보고서 근거를 검색 결과와 원문에 연결하는 식별자

추가 참고

저장소의 docs/rag-learning-guide.md를 기본 교재로 사용하고, docs/rag-service-baseline.md에서 현재 한계와 평가 상태를 확인하세요. 설명과 실제 코드가 다르면 코드·테스트를 기준으로 다시 확인합니다.